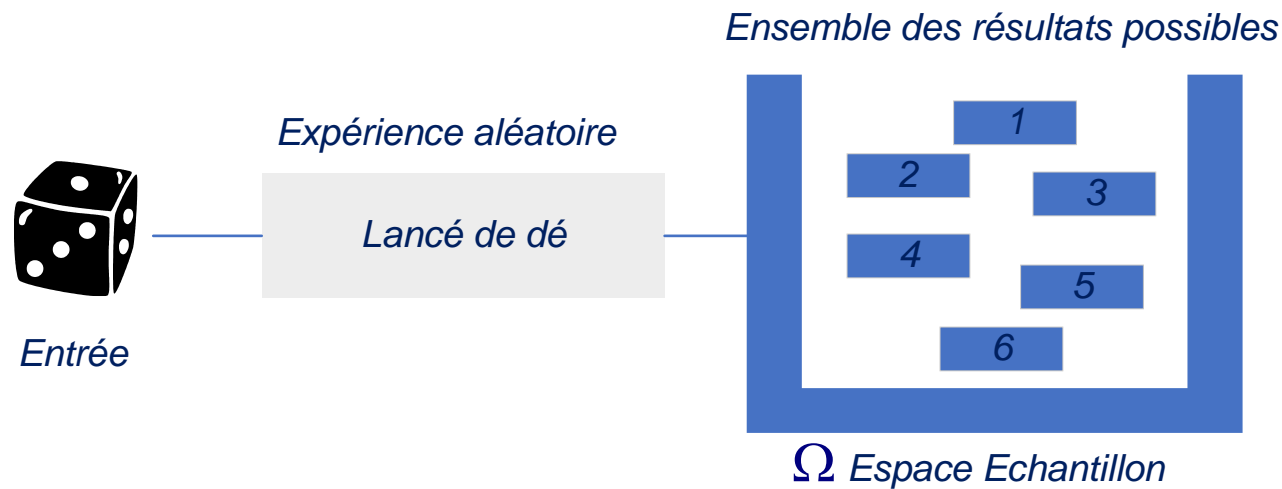


The slide features a decorative border with red and grey horizontal and vertical bars. The top bar is red, followed by a grey bar. The bottom bar is red, with a grey segment in the middle. A vertical grey bar runs down the left side.

ANALYSE DISCRIMINANTE

CLASSIFICATION BAYESIENNE



- **Expérience aléatoire**
Action ou un processus qui engendre une observation dont on ne peut pas prédire à l'avance le résultat
- **Espace échantillon**
L'ensemble des résultats possibles issu d'une expérience aléatoire est appelé espace échantillon
 - Un espace échantillon est discret si l'ensemble des éléments qu'il contient est fini ou infini dénombrable
 - Un espace échantillon est continu si l'ensemble des éléments qu'il contient est infini non dénombrable
- **Evènement**
Proposition logique concernant le résultat d'une expérience
On peut donc considérer qu'un évènement est un sous ensemble de l'espace échantillon (issu d'une expérience aléatoire)
Assertion effectuée a priori : l'expérimentateur décide de s'intéresser à une problématique définie

- Si l'on considère simultanément la réalisation de deux évènements $E1$ et $E2$, il est possible d'effectuer des opérations sur ces ensembles

Exemple : Lors d'un lancé d'un dé, l'expérimentateur décide de s'intéresser aux évènements suivants:



- Obtenir un multiple de 3 : $E1=\{3,6\}$ \longrightarrow Évènement $E1$
- Obtenir un nombre pair $E2=\{2,4,6\}$ \longrightarrow Évènement $E2$


Évènements : propositions logique concernant le résultat d'une expérience

- Pour rappel

- Évènement simple: ne contient qu'un seul résultat Les évènements sont des sous ensembles de Ω
- Évènement certain : contient tous les résultats
- Évènement impossible : ensemble vide

⇒ Intersection

On appelle intersection de deux évènements $E1$ et $E2$, l'évènement qui est réalisé si et seulement si $E1$ et $E2$ le sont. Il est donc constitué des **éventualités** appartenant à la fois à $E1$ et $E2$.




- Propriétés de l'intersection

- Deux évènements E_1 , E_2 sont disjoints s'ils ne peuvent être réalisés simultanément. On a alors $E_1 \cap E_2 = \emptyset$
- $E_1 \cap \bar{E}_1 = \emptyset \longrightarrow$ Évènements incompatibles
- $\Omega \cap E_1 = E_1 \longrightarrow$ Élément neutre
- $\emptyset \cap E_1 = \emptyset \longrightarrow$ Élément absorbant
- $E_1 \cap E_2 = E_2 \cap E_1 \longrightarrow$ Commutativité
- $(E_1 \cap E_2) \cap E_3 = E_1 \cap (E_2 \cap E_3) \longrightarrow$ Associativité
- $(E_1 \cap E_2) \cap E_3 = (E_1 \cap E_3) \cup (E_2 \cap E_3) \longrightarrow$ Transitivité

- \Rightarrow Réunion

On appelle réunion de deux évènements E_1 et E_2 , l'évènement qui est réalisé si et seulement si E_1 ou E_2 est réalisé



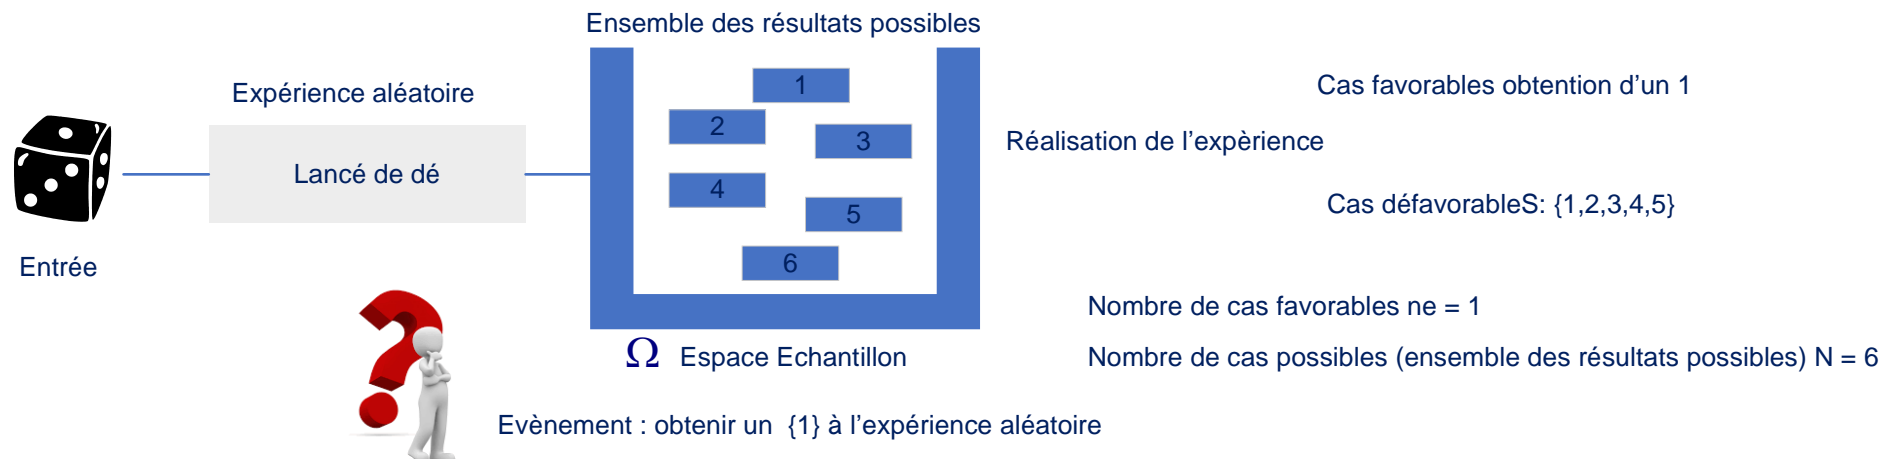
- Propriétés de la réunion

- $E_1 \cup \bar{E}_1 = \Omega$
- $\Omega \cup E_1 = \Omega$
- $\emptyset \cup E_1 = E_1$
- $E_1 \cup E_2 = E_2 \cup E_1$
- $(E_1 \cup E_2) \cup E_3 = E_1 \cup (E_2 \cup E_3)$
- $(E_1 \cup E_2) \cap E_3 = (E_1 \cap E_3) \cup (E_2 \cap E_3)$

Probabilité (simple)

⇒ Définitions

- La probabilité est utilisée pour quantifier la vraisemblance d'un événement issu d'une expérience aléatoire



- Définition classique de la probabilité (dite aussi probabilité a priori)
 - La probabilité d'un évènement E est le rapport entre le nombre de cas favorables (n_e) et le nombre de cas possibles (N)
tous également vraisemblables

Expérience aléatoire

$$\text{probabilité} \longrightarrow P(E=1) = \frac{n_e}{N} = \frac{1}{6} \longrightarrow \text{résultat de l'expérience}$$

↑
évènement

- Approche fréquentiste
 - Elle est fondée sur la répétition (N) de l'expérience aléatoire. A chaque essai, on note le résultat de l'épreuve. Soit n_e le nombre d'apparitions de l'évènement E (ex : résultat = 1)
 - L'approche fréquentiste est utilisée lorsque le décompte du nombre de cas favorables ou le nombre de cas possibles est complexe ou impossible. Il s'agit d'une approche expérimentale

On effectue $n = 1000$ lancers de dé

succès	Lancé du dé
1	5
1	9
1	22
1	23
1	30
1	32
1	33
Obtention d'un '1' au 5 ième lancé	
1	9984
1	9985
1	9987
1	9988
1	9990
1	9994

n_s	N
1	5
2	9
3	22
4	23
5	30
6	32
7	33
1686	9966
1687	9972
1688	9984
1689	9985
1690	9987
1691	9988
1692	9990
1693	9994
somme	

La probabilité que l'évènement se réalise est :


$$\lim_{N \rightarrow \infty} \left(\frac{n_e}{N} \right) = P(E)$$

$$P(E) = \lim_{n \rightarrow \infty} F_n(E) = \frac{n_s}{n}$$

- La probabilité de survenue d'un événement E est un nombre compris entre 0 et 1: $0 \leq P(E) \leq 1$
- La probabilité d'un événement certain = 1: $P(\Omega) = 1$ $P(\emptyset) = 0$
- Soit événement complémentaire: $P(\bar{E}) = 1 - P(E)$
- Si E1 et E2 sont deux événements **incompatibles** $E_1 \cap E_2 = \emptyset$ alors la probabilité de réalisation de l'un **ou** de l'autre est égale à la somme des probabilités $P(E_1 \cup E_2) = P(E_1) + P(E_2)$
- Si E1 et E2 sont deux événements **quelquonques** alors la probabilité de réalisation de l'un **ou** de l'autre est égale à : $P(E_1 \cup E_2) = P(E_1) + P(E_2) - P(E_1 \cap E_2)$
- Si E1 et E2 sont deux événements **quelquonques** alors la probabilité de réalisation de l'un **ou** de l'autre est égale à : $P(E_1 \cup E_2) = P(E_1) + P(E_2) - P(E_1 \cap E_2)$
- Si E1 et E2 sont deux événements indépendants alors: $P(E_1 \cap E_2) = P(E_1) \times P(E_2)$

Attention ! Il ne faut pas confondre indépendance statistique (ex : tirage avec remise) et événements incompatibles

Exemple Obtenir un nombre pair ou un multiple de 3 $\longrightarrow P(E_1 \cup E_2) = P(E_1) + P(E_2) - P(E_1 \cap E_2)$



Obtenir un nombre pair $E_2 = \{2, 4, 6\}$

Obtenir un multiple de 3 : $E_1 = \{3, 6\}$

$$P(E_1) = \frac{2}{6} \quad P(E_2) = \frac{3}{6} \quad P(E_1 \cap E_2) = P(E_1) \times P(E_2) = \frac{3}{6} \times \frac{2}{6} = \frac{1}{6}$$

$$P(E_1 \cup E_2) = \frac{2}{6} + \frac{3}{6} - \frac{1}{6} = \frac{4}{6}$$

- Soit deux événements E_1 et E_2 . On appelle probabilité conditionnelle de E_1 par rapport à E_2 , la probabilité de réalisation de l'évènement E_1 **sachant que l'évènement E_2 s'est réalisé**

E_1 et E_2 sont dépendants
$$P(E_1 / E_2) = \frac{P(E_1 \cap E_2)}{P(E_2)}$$

$$P(E_1 / E_2) = P(E_1)$$

Dans le cas où E_1 et E_2 sont indépendants
$$P(E_2 / E_1) = P(E_2)$$

$$P(E_1 \cap E_2) = P(E_1) \times P(E_2)$$


- Le théorème de Bayes est un outil de modélisation

$$\left. \begin{array}{l} P(E_1 / E_2) = \frac{P(E_1 \cap E_2)}{P(E_2)} \\ P(E_2 / E_1) = \frac{P(E_2 \cap E_1)}{P(E_1)} \end{array} \right\} P(E_1 / E_2) = \frac{P(E_2 / E_1) \times P(E_1)}{P(E_2)}$$

Nous verrons comment utiliser ce théorème et sa signification lors du prochain chapitre///

Obtenir les meilleures séparations possibles entre les classes

Classifier de nouvelles données dans les classes (prédéfinies)



Analyse multidimensionnelle

⇒ X est une matrice (composée de x colonnes, chaque colonne correspondant à une variable)

⇒ La moyenne $\mu = (\mu_1, \mu_2, \dots, \mu_p)$ Dimension (p x 1)

⇒ La Matrice des variances-covariances Dimension (p x p)

$$\Sigma = \begin{pmatrix} \sigma_1^2 & & \\ \sigma_{12}^2 & \sigma_2^2 & \\ \sigma_{13}^2 & \sigma_{23}^2 & \sigma_p^2 \end{pmatrix}$$

Hypothèse forte


Multinormalité : La distribution de probabilité de X (multivariée) sous hypothèse de Normalité

$$X \rightarrow N(\mu, \Sigma) \rightarrow f_X(x) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{-1/2}} e^{\left(-1/2(x-\mu)^t \Sigma^{-1}(x-\mu)\right)}$$

Pour rappel, si $p = 1$ On retrouve la loi normale univariée


$$f_{p=1}(x) = \frac{1}{(2\pi\sigma_1^2)^{1/2}} \exp\left(-\frac{1}{2}\left(\frac{x-\mu_1}{\sigma_1}\right)^2\right)$$

Exemple de distributions multivariées pour $p = 2$ $\mu = (\mu_1, \mu_2)$




$$\mu = (0, 1)$$

$$\Sigma = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$



$$\mu = (0, 1)$$

$$\Sigma = \begin{pmatrix} 0.2 & 0 \\ 0 & 1 \end{pmatrix}$$




$$\mu = (0, 1)$$

$$\Sigma = \begin{pmatrix} 1 & 0.6 \\ 0.6 & 1 \end{pmatrix}$$

● Cas d'un mélange Gaussien (représentation)

Exemple: $p = 2$ et deux classes



$$X_1 \rightarrow N(\mu_{k=1}, \Sigma_{k=1})$$

$$\mu_{k=1} = (0, 0)$$

$$\Sigma_{k=1} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

Soit $\pi = 0.3$: proportion d'observations pour $k = 1$

Soit $1 - \pi = 0.7$: proportion d'observations pour $k = 2$


$$X_2 \rightarrow N(\mu_{k=2}, \Sigma_{k=2})$$

$$\mu_{k=2} = (4, 2)$$

$$\Sigma_{k=2} = \begin{pmatrix} 0.1 & 0 \\ 0 & 1 \end{pmatrix}$$

La densité de probabilité du mélange est :

$$f(X) = \pi f(X_{k=1}) + (1 - \pi) f(X_{k=2})$$



- Généralisation : la densité de probabilité d'un mélange Gaussien est :

$$f(X) = \sum_{k=1}^K \pi_k f(X_k) \quad \text{avec} \quad \sum_{k=1}^K \pi_k = 1$$

Sous la condition de multinormalité $X_k \rightarrow N(\mu_k, \Sigma_k)$

$$f(X_k) = \frac{1}{(2\pi)^{p/2} |\Sigma_k|^{-1/2}} e^{\left(-1/2(x-\mu_k)^t \Sigma_k^{-1}(x-\mu_k)\right)}$$

$X = (X_1, X_2, \dots, X_p)$

Classe C

	X1	X2	Xp
x	● x_1	● x_2	● x_p

k = 1
...
k = 2
...
k =
...
...
...
...


Correspond à la probabilité pour un individus d'observer les valeurs x_1, x_2, x_p sachant qu'il appartient à la classe k

$$P(X = x / Y = C_k) = f(X_k) = \frac{1}{(2\pi)^{p/2} |\Sigma_k|^{-1/2}} \exp\left(-\frac{1}{2}(x - \mu_k)^t \Sigma_k^{-1}(x - \mu_k)\right)$$

● Rappels: Probabilité conditionnelle et règle de Bayes

Soit deux évènements A et B. On appelle probabilité conditionnelle de A par rapport à B, la probabilité de réalisation de l'évènement A sachant que l'évènement B s'est réalisé

$$P(A / B) = \text{probabilité conditionnelle de A sachant que B s'est réalisé} \quad P(A / B) = \frac{P(A \cap B)}{P(B)}$$



● Remarque : Deux évènements sont indépendants si la connaissance de l'un ne modifie pas la connaissance de l'autre

Si deux évènements A et B sont indépendants alors

$$P(A \cap B) = P(A) \times P(B) \quad \rightarrow \quad \begin{aligned} P(A / B) &= P(A) \\ P(B / A) &= P(B) \end{aligned}$$

Règle de Bayes

$$\left. \begin{aligned} P(A / B) &= \frac{P(A \cap B)}{P(B)} \\ P(B / A) &= \frac{P(A \cap B)}{P(A)} \end{aligned} \right\} P(A / B) = \frac{P(B / A) \times P(A)}{P(B)}$$

- Utilisation de la règle de Bayes en analyse discriminante

[illegible]

Soit la variable de groupe $Y \in [C_1, \dots, C_k]$

→ Soit x , une observation que l'on cherche à classer

On Cherche donc à calculer la probabilité d'appartenance à une classe k connaissant les valeurs de $x = (x_1, x_2)$

$$P(Y = C_k / X = x)$$

D'après le théorème de Baye :

theoreme de Baye :

$$P(Y = C_k / X = x) = \frac{\overset{\text{Vraisemblance}}{\downarrow} P(X = x / Y = C_k) \times \overset{\text{Probabilité a priori}}{\downarrow} P(Y = C_k)}{P(X = x)}$$

Vraisemblance

$$P(X = x / Y = C_k) = f(X_k) = \frac{1}{(2\pi)^{p/2} |\Sigma_k|^{-1/2}} \exp\left(-\frac{1}{2}(x - \mu_k)^t \Sigma_k^{-1} (x - \mu_k)\right)$$

Probabilité *a priori*

$$P(Y = C_k) = \pi_k$$

$$P(Y = C_k / X = x) = \frac{P(X = x / Y = C_k) \times P(Y = C_k)}{P(X = x)}$$

$$P(X) = f(X) = \frac{1}{(2p)^{1/p} |\Sigma|^{-1/2}} \exp\left(\frac{1}{2}(x - \mu)^t \Sigma^{-1} (x - \mu)\right)$$

Distribution de probabilité multivariée indépendamment de la classe d'appartenance. La moyenne et la variance sont calculées indépendamment des classes

Pour un nouvel individu, chercher sa classe d'appartenance revient à **maximiser** $P(Y = C_k / X = x)$

- En pratique, on calculera pour cet individu:

$$P(Y = C_{k=1} / X = x)$$

$$P(Y = C_{k=2} / X = x)$$

.....

$$P(Y = C_{k=K} / X = x)$$

$$\arg \max_k (P(Y = C_k / X = x))$$

Remarque importante pour simplification : quelsoit les classes $P(X)$ est la même. Il s'agit donc d'une constante qui n'intervient pas lors de la maximisation

On distingue plusieurs cas

Cas 1: Homoscédasticité et uniformité

$$\begin{aligned} \Sigma_K &= \Sigma \quad \forall_K && \text{Homoscédasticité : même variance pour toutes les classes} \\ \pi_k &\approx \frac{1}{K} && \text{Uniformité: proportion d'observations identiques dans chaque classe} \end{aligned}$$

$$P(Y = C_k / X = x) = \frac{1}{k(2p)^{1/p} |\Sigma|^{-1/2}} \exp\left(\frac{1}{2}(x - \mu_k)^t \Sigma^{-1}(x - \mu_k)\right)$$

On cherche donc $\arg \max_k (P(Y = C_k / X = x))$

Pour simplifier, on passe en log $\arg \max_k (\log(P(Y = C_k / X = x)))$

$$\begin{aligned} &\arg \max_k \left(\log \left(\frac{1}{k(2p)^{1/p} |\Sigma|^{-1/2}} \exp\left(\frac{1}{2}(x - \mu_k)^t \Sigma^{-1}(x - \mu_k)\right) \right) \right) \\ &\arg \max_k \left(-\log(k(2p)^{1/p}) - \frac{1}{2} \log(|\Sigma|) - \frac{1}{2}((x - \mu_k)^t \Sigma^{-1}(x - \mu_k)) \right) \end{aligned}$$

Les proportions et les variances étant identiques pour chaque classe elles ne dépendent pas de la classe

On cherche tout simplement :

$$\arg \max_k \left(-\frac{1}{2}((x - \mu_k)^t \Sigma^{-1}(x - \mu_k)) \right)$$

Cas 2: Homoscédasticité et non uniformité

$\Sigma_K = \Sigma \quad \forall_K$ Homoscédasticité : même variance pour toutes les classes

La proportion d'observations est différente dans chaque classe

$$P(Y = C_k / X = x) = \frac{\pi_k}{(2p)^{1/p} |\Sigma|^{-1/2}} \exp\left(\frac{1}{2}(x - \mu_k)^t \Sigma^{-1}(x - \mu_k)\right)$$

$$\arg \max_k \left(\log(P(Y = C_k / X = x)) \right)$$

$$\arg \max_k \left(+\log(\pi_k) - \log((2p)^{1/p}) - \frac{1}{2} \log(|\Sigma|) - \frac{1}{2}((x - \mu_k)^t \Sigma^{-1}(x - \mu_k)) \right)$$

$$\arg \max_k \left(-\frac{1}{2}((x - \mu_k)^t \Sigma^{-1}(x - \mu_k)) + \log(\pi_k) \right) \quad \text{Score de Fisher}$$

Cas 3: Hétéroscédasticité et non uniformité QDA

$$P(Y = C_k / X = x) = \frac{\pi_k}{(2p)^{1/p} |\Sigma_k|^{-1/2}} \exp\left(\frac{1}{2}(x - \mu_k)^t \Sigma_k^{-1}(x - \mu_k)\right)$$

$$\arg \max_k \left(\log(P(Y = C_k / X = x)) \right)$$

$$\arg \max_k \left(+\log(\pi_k) - \frac{1}{2} \log(|\Sigma_k|) - \frac{1}{2}((x - \mu_k)^t \Sigma_k^{-1}(x - \mu_k)) \right) \quad \text{Fonction discriminante quadratique}$$


Exemple 1: Cas uniforme et même variance 2 groupes ($k = 2$) et 2 variables

$$\pi_1 = \pi_2 = 0.5$$

$$\mu_1 = (0, 0)^t$$

$$\mu_2 = (2, -2)^t$$

$$\Sigma = \begin{pmatrix} 1 & 0 \\ 0 & 0,5626 \end{pmatrix}$$



On développe la fonction discriminante

$$\delta_k = -\frac{1}{2}((x - \mu_k)^t \Sigma^{-1} (x - \mu_k)) + \log(\pi_k) = x^t \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^t \Sigma^{-1} \mu_k - \frac{1}{2} x^t \Sigma^{-1} x + \log(\pi_k)$$

La frontière entre les deux distributions (de la classe 1 et de la classe 2) est $\delta_{k=1} = \delta_{k=2}$

$$\log\left(\frac{\pi_{k=1}}{\pi_{k=2}}\right) - \frac{1}{2}(\mu_{k=1} - \mu_{k=2})^t \Sigma^{-1} (\mu_{k=1} - \mu_{k=2}) + x^t \Sigma^{-1} (\mu_{k=1} - \mu_{k=2}) = 0$$

$$-\frac{1}{2}(-2, +2) \times \begin{pmatrix} 1 & 0 \\ 0 & 0,5626 \end{pmatrix} \times \begin{pmatrix} -2 \\ 2 \end{pmatrix} + (x_1, x_2) \times \begin{pmatrix} 1 & 0 \\ 0 & 0,5626 \end{pmatrix} \times \begin{pmatrix} -2 \\ 2 \end{pmatrix} = 5.56 - 2x_1 + 3.56x_2$$

Exemple 2

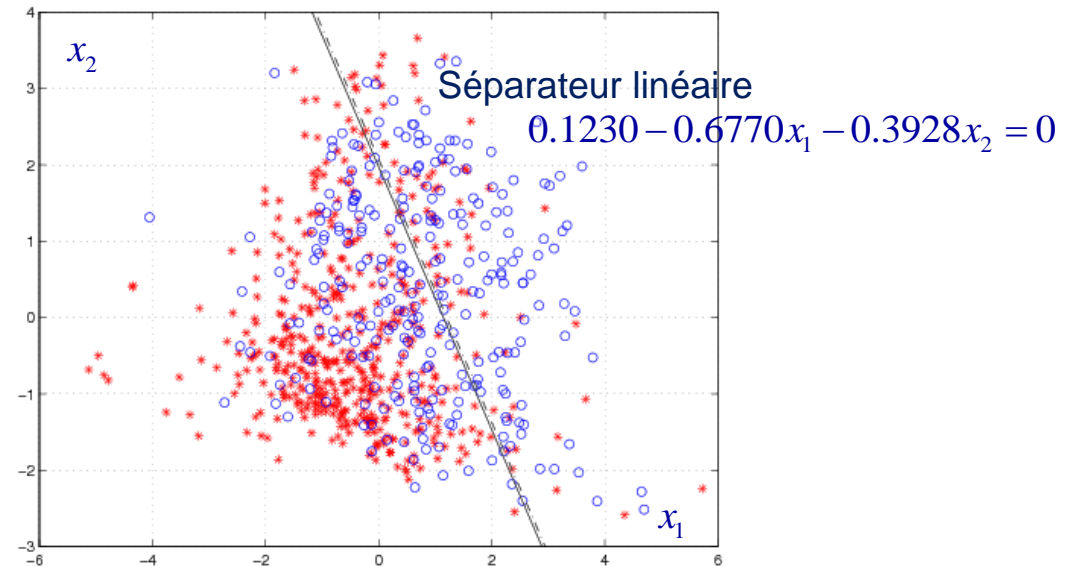
$$\pi_1 = 0.651$$

$$\pi_2 = 0.349$$

$$\mu_1 = (-0.4035, -0.1935)^t$$


$$\mu_2 = (0.7528, 0.3611)^t$$

$$\Sigma = \begin{pmatrix} 1.7925 & -0.1461 \\ -0.1461 & 1.6634 \end{pmatrix}$$

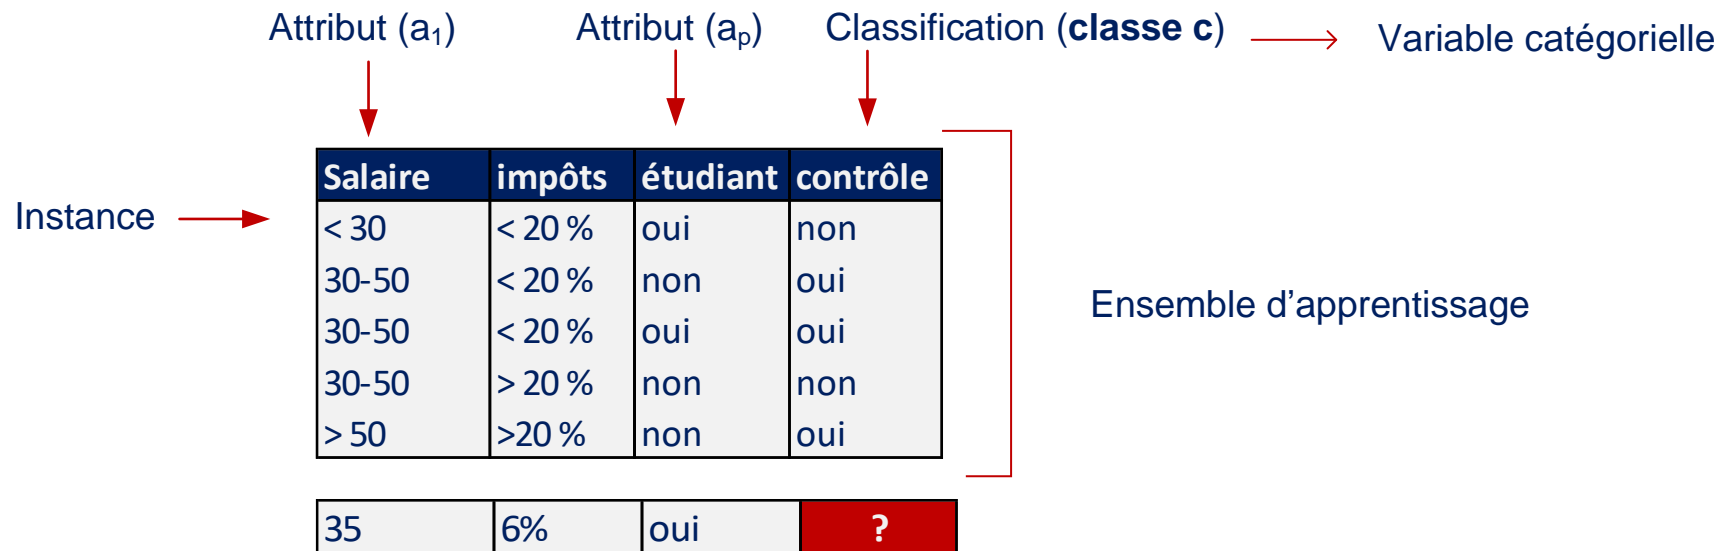
**Exemple 3: Séparateur quadratique**

Le calcul de la fonction de séparation (cf. <https://stats.stackexchange.com/questions/252800/calculate-the-decision-boundary-for-quadratic-discriminant-analysis-qda>)

- ▶ Prior probabilities: $\hat{\pi}_1 = 0.651$, $\hat{\pi}_2 = 0.349$.
- ▶ $\hat{\mu}_1 = (-0.4035, -0.1935)^T$, $\hat{\mu}_2 = (0.7528, 0.3611)^T$.
- ▶ $\hat{\Sigma}_1 = \begin{pmatrix} 1.6769 & -0.0461 \\ -0.0461 & 1.5964 \end{pmatrix}$
- ▶ $\hat{\Sigma}_2 = \begin{pmatrix} 2.0087 & -0.3330 \\ -0.3330 & 1.7887 \end{pmatrix}$



- Le jeu de données est constitué de variables catégorielles (mais pas que..)



L'apprentissage Bayésien permet de faire des prédictions en se basant sur des probabilités

- Pour une instance donnée (un individu – ligne du tableau), quelle sera la classification la plus probable (contrôle oui / non) en fonction de l'ensemble d'apprentissage (données d'entraînement)

Le classifieur Bayésien naïf

On suppose que les descripteurs sont **deux à deux indépendants** conditionnellement aux valeurs de la variable à prédire

- $P(c_k)$ = proportion d'instances de la classe contrôle ($k = \text{oui} / k = \text{non}$)

$$P(\text{contrôle} = \text{oui}) = 3/5$$

$$P(\text{contrôle} = \text{non}) = 2/5$$

- $P(a_1, \dots, a_n)$ = proportion d'instances pour les attributs $a_1 \dots a_p$

contrôle
non
oui
oui
non
oui

Salaire	impôts	étudiant	contrôle
< 30	< 20 %	oui	non
30-50	< 20 %	non	oui
30-50	< 20 %	oui	oui
30-50	> 20 %	non	non
> 50	> 20 %	non	oui

$$P(a_1 \cap a_2 \cap \dots \cap a_p) = P(a_1) \cap P(a_2) \cap \dots \cap P(a_p) = \prod_{i=1}^p P(a_i)$$

si indépendance: Hypothèse forte

Ex: $P(\text{Salaire} < 30 \text{ et Impôt} < 20 \text{ et Etudiant} = \text{Oui})$

$P(\text{Salaire} < 30 \cap \text{Impôt} < 20 \cap \text{Etudiant} = \text{Oui})$

$P(\text{Salaire} < 30) \cap P(\text{Impôt} < 20) \cap P(\text{Etudiant} = \text{Oui})$

$P(\text{Salaire} < 30) \times P(\text{Impôt} < 20) \times P(\text{Etudiant} = \text{Oui})$

$$1/5 \quad \times \quad 3/5 \quad \times \quad 2/5$$

Salaire	impôts	étudiant	contrôle
< 30	< 20 %	oui	non
30-50	< 20 %	non	oui
30-50	< 20 %	oui	oui
30-50	> 20 %	non	non
> 50	> 20 %	non	oui

- Probabilité d'observer une instance **connaissant a priori** la classe d'appartenance

Il s'agit d'une probabilité conditionnelle telle que:

$P(a_1, \dots, a_n / c_k)$ = nombre de fois où l'on rencontre (a_1, \dots, a_n) dans les instances de la classe c_k

Cette probabilité est appelée la **vraisemblance** (a priori)

Si tous les attributs sont indépendants alors, on peut décomposer cette probabilités comme suit:

$$P(a_1 \cap a_2 \cap \dots \cap a_p / c_k) = P(a_1 / c_k) \cap P(a_2 / c_k) \cap \dots \cap P(a_p / c_k) = \prod_{i=1}^p P(a_i / c_k) \longrightarrow \prod_{i=1}^p \frac{P(a_i \cap c_k)}{P(c_k)}$$

Ex: $P(\text{Salaire} < 30 \text{ et Impôt} < 20 \text{ et Etudiant} = \text{Oui} / \text{contrôle} = \text{Oui})$

$P(\text{Salaire} = 30-50 / \text{contrôle} = \text{Oui}) \cap P(\text{Impôt} < 20 / \text{contrôle} = \text{Oui}) \cap P(\text{Etudiant} = \text{Oui} / \text{contrôle} = \text{Oui})$

$P(\text{Salaire} = 30-50 / \text{contrôle} = \text{Oui}) \times P(\text{Impôt} < 20 / \text{contrôle} = \text{Oui}) \times P(\text{Etudiant} = \text{Oui} / \text{contrôle} = \text{Oui})$

$$\begin{array}{ccc} \downarrow & \downarrow & \downarrow \\ \frac{P(\text{Salaire} = 30-50 \cap \text{contrôle} = \text{Oui})}{P(\text{contrôle} = \text{Oui})} = \frac{2/5}{3/5} & = \frac{2/5}{3/5} & = \frac{1/5}{3/5} \end{array}$$

Salaire	impôts	étudiant	contrôle
< 30	< 20 %	oui	non
30-50	< 20 %	non	oui
30-50	< 20 %	oui	oui
30-50	> 20 %	non	non
> 50	>20 %	non	oui

		Etudiant		
		Oui	Non	tot
Contrôle	Oui	1	2	3
	Non	1	1	2
	Tot	2	3	5

Etudiant = Oui et Contrôle = Oui sont dépendants

- On sait donc calculer les probabilités de chaque instance connaissant a priori la classe d'appartenance $\prod_{i=1}^p \frac{P(a_i \cap c_k)}{P(c_k)}$

On cherche à calculer la classe d'appartenance en fonction des instances

35	6%	oui	?	probabilité d'appartenance à une classe
----	----	-----	---	---

connaissant les valeurs des instances

On cherche à calculer la probabilité d'appartenance à une classe connaissant les valeurs des instances et donc

$$P(c_k / a_1, a_2, \dots, a_p) = P(c_k / a_1 \cap a_2 \cap \dots \cap a_p)$$

Pour y parvenir, on utilise le théorème de Bayes

$$\left. \begin{aligned} P(E_1 / E_2) &= \frac{P(E_1 \cap E_2)}{P(E_2)} \\ P(E_2 / E_1) &= \frac{P(E_2 \cap E_1)}{P(E_1)} \end{aligned} \right\} P(E_1 / E_2) = \frac{P(E_2 / E_1) \times P(E_1)}{P(E_2)}$$

$$P(c_k / a_1, a_2, \dots, a_p) = \frac{\overset{\text{Vraisemblance}}{P(a_1, a_2, \dots, a_p / c_k)} \times \overset{\text{Probabilité à priori}}{P(c_k)}}{\underset{\text{Probabilité à postérieure}}{P(a_1, a_2, \dots, a_p)}}$$

Pour chaque instance, on calcule les probabilités a posteriori pour le contrôle = Oui et le contrôle = Non

$P(\text{contrôle} = \text{Oui} / \text{salaire} = 30\text{-}50 \text{ et impôt} < 20\% \text{ et étudiants} = \text{Oui})$

$P(\text{contrôle} = \text{Non} / \text{salaire} = 30\text{-}50 \text{ et impôt} < 20\% \text{ et étudiants} = \text{Oui})$

$$P(c_k / a_1, a_2, \dots, a_p) = \frac{P(a_1, a_2, \dots, a_p / c_k) \times P(c_k)}{P(a_1, a_2, \dots, a_p)}$$

$P(\text{contrôle} = \text{Oui} / \text{salaire} = 30\text{-}50 \text{ et impôt} < 20\% \text{ et étudiants} = \text{Oui})$

=

$\frac{P(\text{salaire} = 30\text{-}50 \text{ et impôt} < 20\% \text{ et étudiants} = \text{Oui} / \text{contrôle} = \text{Oui}) \times P(\text{contrôle} = \text{Oui})}{P(\text{salaire} = 30\text{-}50 \text{ et impôt} < 20\% \text{ et étudiants} = \text{Oui})}$

$P(\text{contrôle} = \text{Non} / \text{salaire} = 30\text{-}50 \text{ et impôt} < 20\% \text{ et étudiants} = \text{Oui})$

=

$\frac{P(\text{salaire} = 30\text{-}50 \text{ et impôt} < 20\% \text{ et étudiants} = \text{Oui} / \text{contrôle} = \text{Non}) \times P(\text{contrôle} = \text{Non})}{P(\text{salaire} = 30\text{-}50 \text{ et impôt} < 20\% \text{ et étudiants} = \text{Oui})}$

- On choisit la classe la plus probable (Probabilité maximum a posteriori)

$$h_{MAP} = \arg \max_{c_k} \left(\frac{P(a_1, a_2, \dots, a_n / c_k) * P(c_k)}{P(a_1, a_2, \dots, a_n)} \right)$$

$$P(a_1, a_2, \dots, a_n) = Cte \quad (\text{Indépendante de la variable à prédire})$$

On sélection la probabilité telle que $h_{MAP} = \arg \max_{c_k} (P(a_1, a_2, \dots, a_n / c_k) * P(c_k))$

- Retour à l'exemple

$$P(\text{salaire} = 30-50 \text{ et impôt} < 20\% \text{ et étudiants} = \text{Oui} /) \times P(\text{contrôle} = \text{Oui})$$

1

2

$$P(\text{salaire} = 30-50 \text{ et impôt} < 20\% \text{ et étudiants} = \text{Oui} / \text{contrôle} = \text{Oui} /) \quad P(\text{contrôle} = \text{Oui}) = 3/5$$

$$1 \rightarrow P(\text{Salaire} = 30-50 / \text{contrôle} = \text{Oui}) \times P(\text{Impôt} < 20 / \text{contrôle} = \text{Oui}) \times P(\text{Etudiant} = \text{Oui} / \text{contrôle} = \text{Oui})$$

		Salaire			contrôle
		< 30	30-50	> 50	
contrôle	Oui	0	2	1	3
	Non	1	1	0	2
	Salaire	1	3	1	5

2/3

		Impot		contrôle
		<20	>20	
contrôle	Oui	2	1	3
	Non	1	1	2
	impot	3	2	5

2/3

		Etudiant		contrôle
		Oui	Non	
contrôle	Oui	1	2	3
	Non	1	1	2
	impot	2	3	5

1/3

$$P(\text{Salaire} = 30-50 / \text{contrôle} = \text{Oui}) \times P(\text{Impôt} < 20 / \text{contrôle} = \text{Oui}) \times P(\text{Etudiant} = \text{Oui} / \text{contrôle} = \text{Oui})$$

$$=$$

$$2/3 \times 2/3 \times 1/3 = 0.148$$

$$P(\text{contrôle} = \text{Oui} / \text{salaire} = 30-50 \text{ et impôt} < 20\% \text{ et étudiants} = \text{Oui}) \times P(\text{contrôle} = \text{Oui}) = 0.148 * 0.6 = 0.088$$

$$P(\text{contrôle} = \text{Non} / \text{salaire} = 30-50 \text{ et impôt} < 20\% \text{ et étudiants} = \text{Oui}) \times P(\text{contrôle} = \text{Non})$$

1

2

$$P(\text{contrôle} = \text{Non}) = 2/5$$

$$P(\text{Salaire} = 30-50 / \text{contrôle} = \text{Non}) \times P(\text{Impôt} < 20 / \text{contrôle} = \text{Non}) \times P(\text{Etudiant} = \text{Oui} / \text{contrôle} = \text{Non})$$

		Salaire			contrôle
		< 30	30-50	> 50	
contôle	Oui	0	2	1	3
	Non	1	1	0	2
	Salaire	1	3	1	5

1/2

		Impot		contrôle
		<20	>20	
contôle	Oui	2	1	3
	Non	1	1	2
	impot	3	2	5

1/2

		Etudiant		contrôle
		Oui	Non	
contôle	Oui	1	2	3
	Non	1	1	2
	impot	2	3	5

1/2

$$P(\text{Salaire} = 30-50 / \text{contrôle} = \text{Non}) \times P(\text{Impôt} < 20 / \text{contrôle} = \text{Non}) \times P(\text{Etudiant} = \text{Oui} / \text{contrôle} = \text{Non})$$

$$=$$

$$1/2 \times 1/2 \times 1/2 = 0.125$$

$$P(\text{contrôle} = \text{Non} / \text{salaire} = 30-50 \text{ et impôt} < 20\% \text{ et étudiants} = \text{Oui}) \times P(\text{contrôle} = \text{Non}) = 0.125 \times 0.4 = 0.05$$

$$P(a_1, a_2, \dots, a_p / c = \text{Oui}) > P(a_1, a_2, \dots, a_n / c = \text{Non})$$

On effectue un contrôle fiscal

Correctif sur le calcul de la vraisemblance

En pratique, on utilise un facteur correctif (qui permet de « lisser » les estimations) ce qui évite d'obtenir des probabilités conditionnelles nulles et par conséquent des vraisemblances nulles

		Salaire			contrôle
		< 30	30-50	> 50	
contôle	Oui	0	2	1	3
	Non	1	1	0	2
	Salaire	1	3	1	5

$$P(\text{Salaire} < 30 / \text{Controle} = \text{Oui}) = \frac{P(\text{Salaire} < 30 \cap \text{Controle} = \text{Oui})}{P(\text{Controle} = \text{Oui})}$$

$$P(\text{Salaire} < 30 \cap \text{Controle} = \text{Oui}) = 0!$$

- Pour palier au problème de probabilité conditionnelle nulle, on utilise l'estimateur Laplacien des probabilités

		Salaire			contrôle
		< 30	30-50	> 50	
contôle	Oui	0	2	1	3
	Non	1	1	0	2
	Salaire	1	3	1	5

$$P(a_i / c_k) = \frac{n_{kl}}{n_k} \longrightarrow P(a_i / c_k) = \frac{n_{kl} + m}{n_k + mk} \quad \begin{matrix} m = 1 \\ k = \text{nombre de niveaux de la variable à prédire} \end{matrix}$$

- Nouvelle estimation $P(\text{Salaire} < 30 / \text{Controle} = \text{Oui}) = \frac{P(\text{Salaire} < 30 \cap \text{Controle} = \text{Oui})}{P(\text{Controle} = \text{Oui})} = \frac{1}{(3 + 2)}$
- On applique cette modification pour le calcul de toutes les probabilités conditionnelles
- Il n'y a pas de modification du critère de décision (h_{MAP})

Données manquantes

Les données manquantes sont traitées de façon satisfaisante par le classifieur. Pour l'estimation des probabilités, ces valeurs sont tout simplement ignorées

Salaire	impôts	étudiant	contrôle
< 30	< 20 %	oui	non
30-50	< 20 %	non	oui
?	< 20 %	oui	oui
30-50	> 20 %	non	non
> 50	> 20 %	non	oui

$$P(\text{Salaire} = 30-50 / \text{contrôle} = \text{Oui}) \cap P(\text{Impôt} < 20 / \text{contrôle} = \text{Oui}) \cap P(\text{Etudiant} = \text{Oui} / \text{contrôle} = \text{Oui}) \\ 1 \times P(\text{Impôt} < 20 / \text{contrôle} = \text{Oui}) \times P(\text{Etudiant} = \text{Oui} / \text{contrôle} = \text{Oui})$$

● Variables prédictives numériques

Salaire	impôts	étudiant	contrôle
18	< 20 %	oui	non
22	< 20 %	oui	non
35	< 20 %	non	oui
40	< 20 %	oui	oui
44	> 20 %	non	non
56	>20	non	oui
58	>20 %	non	oui

→ Calcul des probabilités conditionnelles pour la variable salaire

$$P(\text{Salaire} / \text{Contrôle} = \text{Oui})$$

$$P(\text{Salaire} / \text{Contrôle} = \text{Non})$$

- Pour calculer les probabilités conditionnelles d'une variable numérique a , on suppose que la distribution de cette variable suit **une distribution normale** pour chaque niveau de facteur de la variable c_k

$$a_{c_k} \rightarrow \mathbb{N}(\mu_{a,c_k}, \sigma_{a,c_k}^2)$$

Densité de probabilité

$$F_{p,c_k}(x) = \frac{1}{\sigma_{p,c_k} \sqrt{2\pi}} \int_{-\infty}^x \exp\left(-\frac{(x - \mu_{p,c_k})^2}{2\sigma_{p,c_k}^2}\right) dx$$

- Concernant notre exemple : pour la variable salaire

$$\text{Salaire}_{\text{contrôle=Oui}} \rightarrow \mathbb{N}(\mu_{\text{contrôle=Oui}}, \sigma_{\text{contrôle=Oui}}^2)$$

$$\text{Salaire}_{\text{contrôle=Non}} \rightarrow \mathbb{N}(\mu_{\text{contrôle=Non}}, \sigma_{\text{contrôle=Non}}^2)$$

$$f_{\text{contrôle=Oui}}(x) = \frac{1}{\sigma_{\text{contrôle=Non}} \sqrt{2\pi}} \exp\left(-\frac{(x - \mu_{\text{contrôle=Oui}})^2}{2\sigma_{\text{contrôle=Oui}}^2}\right)$$

$$f_{\text{contrôle=Non}}(x) = \frac{1}{\sigma_{\text{contrôle=Non}} \sqrt{2\pi}} \exp\left(-\frac{(x - \mu_{\text{contrôle=Non}})^2}{2\sigma_{\text{contrôle=Non}}^2}\right)$$

Probabilité conditionnelle pour $x = 38$?

	Contrôle	
	Oui	Non
35		18
40		22
56		44
58		
Moyenne	47,25	28,00
ecart type	11,47	14,00

$$f_{\text{contrôle=Non}} = P(\text{Salaire} = 38 / \text{contrôle} = \text{Non}) = 0.0220$$

$$f_{\text{contrôle=Oui}} = P(\text{Salaire} = 38 / \text{contrôle} = \text{Oui}) = 0.0251$$

Le fonction h_{map} est passée en logarithme. On cherche donc à minimiser le log de la vraisemblance à posteriori

$$h_{MAP} = \arg \max_{c_k} \left(\frac{P(a_1, a_2, \dots, a_n / c_k) * P(c_k)}{P(a_1, a_2, \dots, a_n)} \right)$$

$$\log(h_{map}) = \arg \max \left(\log(P(a_1, a_2, \dots, a_n / c_k)) + \log(P(c_k) - \log(P(a_1, a_2, \dots, a_n))) \right)$$

Sachant que $\log(P(a_1, a_2, \dots, a_n)) = cte$

$$\log(h_{map}) = \arg \max \left(\log(P(a_1, a_2, \dots, a_n / c_k)) + \log(P(c_k)) \right)$$

$$\log(h_{map}) = \arg \max \left(\log \left(\sum_{i=1}^n P(a_i / c_k) \right) + \log(P(c_k)) \right)$$

D'un point de vue calculatoire, le produit de nombreuses probabilités (toutes inférieures à 1) provoque rapidement des débordements de capacité de la mémoire même en utilisant des flottants à double précision. Le passage en log permet d'éviter ce problème.

- Présente de bonnes performances (comparables à d'autres techniques plus « sophistiquées »)
- Facile à programmer, rapidité de calcul et capacité à traiter de très grandes bases
- Très robuste
- Règles d'affectations non interprétables et non explicites (comme d'autres algos...) car on ne peut pas estimer comme chaque variable « pèse » sur la décision
- Les données numériques ne sont pas toujours distribuées selon une loi normale. Dans ce cas, on peut toujours utiliser des transformations (Cox-Box)